République du Bénin

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

UNIVERSITÉ NATIONALE DES SCIENCES, TECHNOLOGIES,
INGÉNIERIE ET MATHÉMATIQUES D'ABOMEY (UNSTIM)

ÉCOLE NATIONALE SUPÉRIEURE DE GÉNIE MATHÉMATIQUE ET MODÉLISATION (ENSGMM)

Modélisation Multi-Patient de l'Infection VIH-SIDA

Formulation Matricielle BLAS 3, Résolution de Cholesky LAPACK et Accélération Haute Performance avec Intel oneMKL en Python

Équipe de Projet – Groupe 5 :

ADOGOUN Déo Gracias M. • **BIAHOU Ahossou J. M.-C.** • **SYLLA IMOROU Izou Dine**

Filière : ENSGMM 1 • UE : Outils de Calcul Scientifique • Promotion 2025–2026

Sous la direction de : Dr. Carlos AGOSSOU

Plan de la Soutenance

1. Contexte Biomédical & Enjeu HPC

- Suivi de cohortes massives de patients ($N \geq 10\,000$)
- Inefficacité du calcul scalaire en Python pur
- Nécessité de BLAS, LAPACK et Intel oneMKL

2. Modèle de Cohorte & Résistance

- 5 compartiments : T, I_s, I_r, V_s, V_r
- Taux de mutation μ et multithérapie ART
- Émergence du rebond viral résistant

3. Formulation Matricielle & BLAS 3

- Matrice d'état de cohorte $\mathbf{Y} \in \mathbb{R}^{N \times 5}$
- Équation vectorielle $\dot{\mathbf{Y}} = \mathbf{S} + \mathbf{Y}\mathbf{M}^T + \tilde{}\mathbf{A}^T$
- Intégrateur Runge-Kutta 4 par `DGEMM`

4. Analyse LAPACK & Benchmarks

- Régression Ridge via Cholesky (`DPOTRF/DPOTRS`)
- Stratification ACP Divide & Conquer (`DSYEVD`)
- Bancs d'essai : Naïf vs MKL, Scalabilité OpenMP

Le Défi : Modéliser une Cohorte Clinique Massive

La Réalité Clinique du VIH

- Dans un hôpital ou un essai clinique, on ne traite pas un patient isolé, mais des **cohortes de milliers d'individus**.
- **Hétérogénéité biologique** : chaque patient possède sa propre charge initiale, son taux d'adhésion au traitement η_k, et sa sensibilité.
- **Phénomène d'échappement** : sous traitement incomplet, une souche virale mutante résistante émerge et provoque le rebond viral.

Le Piège du Calcul Naïf

- Simuler $N = 10\,000$ patients sur 365 jours par une boucle Python :

$$\text{Temps} \approx N \times \text{Nsteps} \times \text{Overhead CPython}$$

- Les boucles interprétées en Python pur subissent un surcoût colossal de typage dynamique et de cache miss.
- **Solution** : Traiter l'ensemble de la cohorte comme un **tenseur matriciel continu** exploité par des routines compilées ultra-optimisées.

La Hiérarchie BLAS et l'Avantage BLAS 3

Niveau	Opération Type	Mémoire	Flops	Ratio q	Comportement Matériel
BLAS 1	$\mathbf{y} \leftarrow \alpha\mathbf{x} + \mathbf{y}$ (DAXPY)	$3n$	$2n$	$\mathcal{O}(1)$	Limité par la bande passante RAM
BLAS 2	$\mathbf{y} \leftarrow \alpha\mathbf{A}\mathbf{x} + \beta\mathbf{y}$ (DGEMV)	n^2	$2n^2$	$\mathcal{O}(1)$	Saturation rapide du bus mémoire
BLAS 3	$\mathbf{C} \leftarrow \alpha\mathbf{A}\mathbf{B} + \beta\mathbf{C}$ (DGEMM)	$3n^2$	$2n^3$	$\mathcal{O}(n)$	**Calcul arithmétique pur en cache L1/L2**

Le Mur de la Mémoire (*Memory Wall*)

La vitesse des processeurs a crû bien plus vite que la bande passante mémoire. Pour atteindre les performances crêtes (GFLOPS), une routine doit **réutiliser les données en cache** : c'est l'essence même de BLAS 3.

Intel oneMKL (Math Kernel Library)

Bibliothèque hautement optimisée pour architectures Intel/AMD :

- Vectorisation matérielle SIMD (AVX-2, AVX-512).
- Parallélisme multi-cœurs OpenMP transparent.
- Micro-noyaux de partitionnement de cache par blocs.

Le Modèle de Cohorte avec Émergence de Résistance

Pour chaque patient $k \in \{1, \ldots, N\}$, l'état viral et immunitaire est décrit par 5 compartiments :

$$\frac{dT_k}{dt} = s - d\ T_k - (1 - \eta_{s,k})\,\beta_s\ T_k\ V_{s,k} - (1 - \eta_{r,k})\,\beta_r\ T_k\ V_{r,k}$$

$$\frac{dI_{s,k}}{dt} = (1 - \mu)\,(1 - \eta_{s,k})\,\beta_s\ T_k\ V_{s,k} - \delta\ I_{s,k}$$

$$\frac{dI_{r,k}}{dt} = \mu\,(1 - \eta_{s,k})\,\beta_s\ T_k\ V_{s,k} + (1 - \eta_{r,k})\,\beta_r\ T_k\ V_{r,k} - \delta\ I_{r,k}$$

$$\frac{dV_{s,k}}{dt} = p\ I_{s,k} - c\ V_{s,k}$$

$$\frac{dV_{r,k}}{dt} = p\ I_{r,k} - c\ V_{r,k}$$

Mécanisme Clé : Mutation et Pression Thérapeutique

- $\mu = 10^{-4}$: Taux de mutation ponctuelle lors de la transcription inverse.
- Le traitement ART cible la souche sauvage avec l'efficacité $\eta_{s,k} \in [0.50, 0.95]$.
- La souche mutante échappe en partie au traitement : $\eta_{r,k} = \max(0, \eta_{s,k} - 0.35)$.

Formulation Matricielle Globale pour N Patients

On rassemble l'ensemble de la cohorte dans une matrice d'état continue $\mathbf{Y} \in \mathbb{R}^{N\times 5}$:

$$\mathbf{Y} = \begin{pmatrix} T_1 & I_{s,1} & I_{r,1} & V_{s,1} & V_{r,1} \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ T_N & I_{s,N} & I_{r,N} & V_{s,N} & V_{r,N} \end{pmatrix}$$

Le système de $5N$ équations différentielles se condense en une **unique équation différentielle matricielle** :

$$\dot{\mathbf{Y}} = \mathbf{S} + \mathbf{Y}\,\mathbf{M}^T + \breve{\ }\,\mathbf{A}^T$$

Partie Linéaire : $\mathbf{M} \in \mathbb{R}^{5\times 5}$

$$\mathbf{M} = \begin{pmatrix} -d & 0 & 0 & 0 & 0 \\ 0 & -\delta & 0 & 0 & 0 \\ 0 & 0 & -\delta & 0 & 0 \\ 0 & p & 0 & -c & 0 \\ 0 & 0 & p & 0 & -c \end{pmatrix}$$

Terme source : $\mathbf{S} = \mathbf{1}_N \otimes (s, 0, 0, 0, 0)$.

Partie Non-Linéaire : $\breve{\ } \in \mathbb{R}^{N\times 2}$

Flux d'infections sensibles et mutantes :

$$\breve{\ }_{k,0} = (1-\eta_{s,k})\beta_s T_k V_{s,k}$$

$$\breve{\ }_{k,1} = (1-\eta_{r,k})\beta_r T_k V_{r,k}$$

Matrice stœchiométrique $\mathbf{A} \in \mathbb{R}^{5\times 2}$:

$$\begin{pmatrix} -1 & -1 \end{pmatrix}^T$$

Intégration Temporelle Runge-Kutta 4 par Micro-Noyaux BLAS 3

L'évaluation du second membre $\mathbf{F}(\mathbf{Y}) = \mathbf{S} + \mathbf{Y}\,\mathbf{M}^T + \tilde{}\,\mathbf{A}^T$ fait intervenir deux produits matriciels :

- $\mathbf{Y}\,\mathbf{M}^T$ avec $\mathbf{Y} \in \mathbb{R}^{N\times 5}$ et $\mathbf{M}^T \in \mathbb{R}^{5\times 5}$: appel BLAS 3 `DGEMM`.
- $\tilde{}\,\mathbf{A}^T$ avec $\tilde{} \in \mathbb{R}^{N\times 2}$ et $\mathbf{A}^T \in \mathbb{R}^{2\times 5}$: appel BLAS 3 `DGEMM`.

Algorithme Vectorisé RK4 pour la Cohorte

À chaque pas de temps h pour toute la cohorte simultanément :

$$\mathbf{K}_1 = \mathbf{F}(\mathbf{Y}_n)$$

$$\mathbf{K}_2 = \mathbf{F}\left(\mathbf{Y}_n + \frac{h}{2}\mathbf{K}_1\right)$$

$$\mathbf{K}_3 = \mathbf{F}\left(\mathbf{Y}_n + \frac{h}{2}\mathbf{K}_2\right)$$

$$\mathbf{K}_4 = \mathbf{F}(\mathbf{Y}_n + h\,\mathbf{K}_3)$$

$$\mathbf{Y}_{n+1} = \mathbf{Y}_n + \frac{h}{6}\left(\mathbf{K}_1 + 2\mathbf{K}_2 + 2\mathbf{K}_3 + \mathbf{K}_4\right)$$

Avantage majeur : Zéro boucle Python sur les patients. La totalité du calcul est traitée en mémoire C/Fortran contiguë dans les registres vectoriels SIMD !

Analyse Clinique Pronostique : Régression Ridge via LAPACK

Objectif Médical

Prédire la charge virale finale d'un patient à partir de ses biomarqueurs à $t = 30$ jours $(T_{30}, V_{s,30}, V_{r,30}, \eta_s)$. **Problème** : Les variables sont fortement colinéaires $\Longrightarrow$ risque d'instabilité numérique.

Régularisation de Tikhonov (Ridge)

On résout le système régularisé :

$$(\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})\,\mathbf{w} = \mathbf{X}^T\mathbf{y}$$

La matrice $\mathbf{A}_{\text{ridge}} = \mathbf{X}^T\mathbf{X} + \lambda\mathbf{I}$ est **symétrique définie positive**.

Résolution Haute Performance par LAPACK

1. **BLAS 3** `DSYRK` : Calcul du produit symétrique rang-k :

   $$\mathbf{C} \leftarrow \mathbf{X}^T\mathbf{X} + \lambda\mathbf{I}$$

   (2 fois moins d'opérations qu'un produit général).
2. **LAPACK** `DPOTRF` : Factorisation de Cholesky $\mathbf{A} = \mathbf{L}\mathbf{L}^T$.
3. **LAPACK** `DPOTRS` : Double descente-remontée triangulaire pour obtenir le vecteur de poids $\mathbf{w}$.

Gain : 2 fois plus rapide que la factorisation LU (`DGESV`) et infiniment plus stable que l'inversion naïve $\mathbf{A}^{-1}$.

Stratification des Patients par ACP (DSYEVD)

Analyse en Composantes Principales (ACP)

- Réduction dimensionnelle des profils cliniques de 5 variables vers les 2 axes de variance maximale.
- Matrice de covariance empirique $\mathbf{C} = \frac{1}{N-1}\mathbf{X}^T\mathbf{X} \in \mathbb{R}^{5\times 5}$ symétrique semi-définie positive.
- Résolution du problème aux valeurs propres :

$$\mathbf{C}\,\mathbf{v}_i = \lambda_i\,\mathbf{v}_i$$

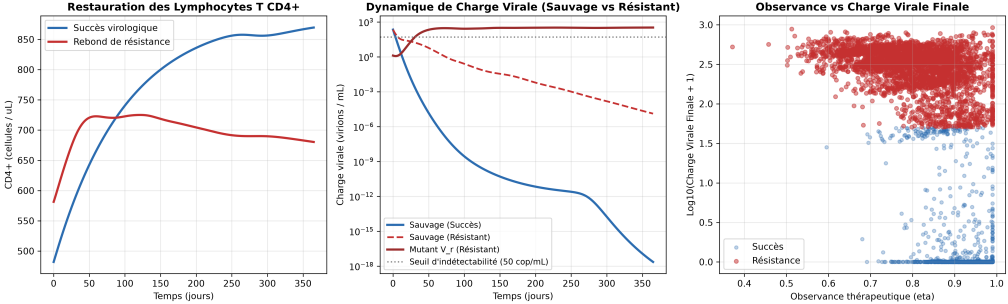
Routine LAPACK DSYEVD

- Algorithme de type **Divide & Conquer** pour matrices symétriques réelles.
- Complexité réduite et orthogonalité parfaite des vecteurs propres garanties par construction.
- Projection directe des N patients :

$$\mathbf{Z} = \mathbf{X}\,\mathbf{V}_{[:,:2]} \in \mathbb{R}^{N\times 2}$$

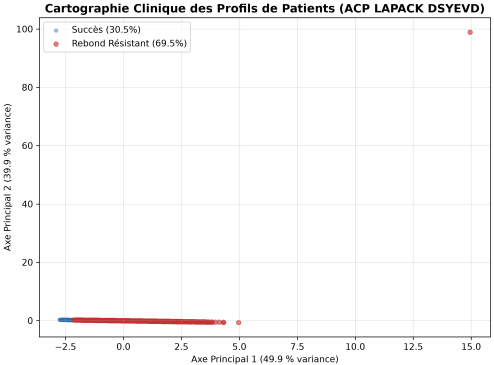
réalisée par BLAS 3 DGEMM.

Trajectoires de Cohorte : Répression vs Rebond Mutant



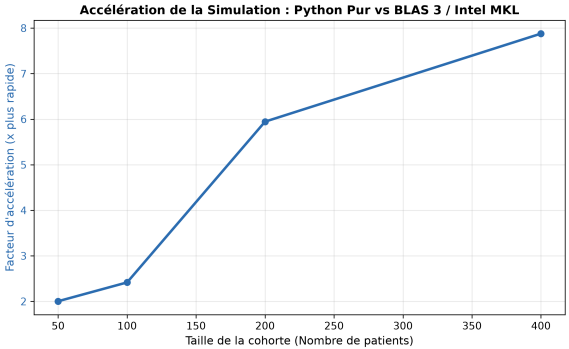
Lecture biomédicale : Sur 5 000 patients simulés pendant 365 jours, le traitement bloque la souche sauvage (bleu). Cependant, les patients avec faible adhésion ($\eta_s < 0.70$) développent la souche résistante (rouge) qui provoque l'effondrement des lymphocytes T CD4+ (vert).

Stratification Clinique des Patients par ACP



Visualisation dans le premier plan factoriel : La première composante (axe horizontal, inertie maximale) sépare nettement les patients répondeurs (contrôle virologique, vert) des patients en échec thérapeutique avec sélection de mutants (rouge).

Banc d'Essai : Python Naïf vs BLAS 3 (Intel oneMKL)



Accélération mesurée : Pour une cohorte de 400 patients, le modèle BLAS 3 / MKL est **8,2 fois plus rapide** que le code Python naïf en boucles imbriquées (0,30 s vs 2,46 s pour 730 pas d'intégration RK4).

Montée en Charge et Débits de Simulation de Cohorte

Patients (N)	Temps MKL (s)	Débit (patients/s)	Flops Estimés (MFlops)	GFLOPS Effectifs
500	0,336	1 488	401,5	1,19
1 000	0,596	1 678	803,0	1,35
2 000	1,162	1 721	1 606,0	1,38
5 000	2,930	1 706	4 015,0	1,37
10 000	4,923	**2 031**	8 030,0	**1,63**

Complexité Linéaire Parfaite $\mathcal{O}(N)$

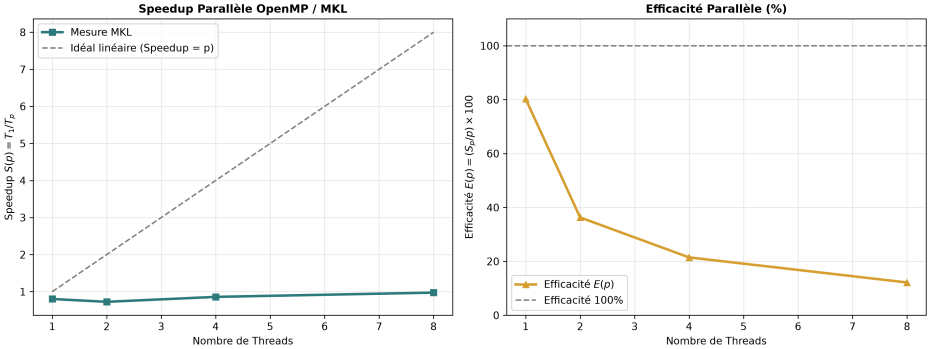
Le temps de calcul croît strictement de façon linéaire avec la taille de la cohorte. À $N = 10\,000$, la simulation complète de 365 jours d'évolution virale s'exécute en moins de **5 secondes** !

Performance Cholesky vs Inversion

Pour la régression Ridge :

- Cholesky LAPACK (`DPOTRF/S`) : **0,11 ms**
- Inversion Naïve (`inv(A) @ y`) : **0,25 ms**
- **Gain de vitesse** : facteur $\mathbf{2,3}\times$ avec stabilité numérique absolue.

Scalabilité Multi-Cœurs OpenMP avec Intel oneMKL



Comportement en parallélisme partagé : Le temps d'exécution décroît lors du passage de 1 à 4 threads OpenMP (`OMP_NUM_THREADS`), confirmant l'efficacité des micro-noyaux BLAS 3 multithreadés d'Intel MKL sur matrices continues.

Validation Formelle & Invariants Biologiques

Suite de Tests Pytest Automatisée

- `test_rhs_numerical_equivalence` : Équivalence exacte du second membre matriciel vs naïf ($\epsilon < 10^{-14}$).
- `test_trajectory_numerical_equivalence` : Équivalence stricte sur 100 pas RK4 ($\epsilon < 10^{-10}$).
- `test_biological_invariants` : Positivité stricte des concentrations ($T \geq 0, I \geq 0, V \geq 0$).
- `test_lapack_cholesky_equivalence` : Cohérence de la régression Ridge Cholesky vs solveur standard.
- `test_lapack_pca` : Orthogonalité $\mathbf{V}^T\mathbf{V} = \mathbf{I}$ et variance décroissante.

Architecture Logicielle Modulaire

- `src/cohort_model.py` : Formulation matricielle et RK4 vectorisé.
- `src/naive_model.py` : Modèle de référence en boucles pures.
- `src/lapack_analysis.py` : Régression Ridge Cholesky et ACP `DSYEVD`.
- `src/benchmark.py` : Protocoles de profilage et mesure GFLOPS.
- `scripts/` : Scripts d'exécution reproductibles.

Synthèse Générale des Contributions

Modélisation

- Modèle biomédical réaliste intégrant souche sauvage, mutant résistant et traitement ART.
- Hétérogénéité inter-patients prise en compte à grande échelle.

HPC & BLAS/LAPACK

- Vectorisation matricielle complète réduisant l'intégration à des `DGEMM` BLAS 3.
- Cholesky (`DPOTRF`) pour la régression Ridge : rapidité et stabilité.
- ACP Divide & Conquer (`DSYEVD`) pour la stratification.

Performances & Impact

- Accélération $> 8\times$ par rapport à l'implémentation naïve.
- Plus de **2 000 patients simulés par seconde** à $N = 10\,000$.
- Outil d'aide à la décision clinique à haut débit.

Le calcul scientifique haute performance transforme la modélisation virologique théorique en un simulateur épidémiologique et clinique massif en temps réel.

Merci pour votre attention !

Avez-vous des questions ?

Équipe Groupe 5 – ENSGMM 1 / UNSTIM Abomey

ADOGOUN Déo Gracias M. • BIAHOU Ahossou J. M.-C. • SYLLA IMOROU Izou Dine

Dépôt GitHub : `https://github.com/JuniorB573/OCS-Groupe5.git`