République du Bénin

Ministère de l'Enseignement Supérieur et de la Recherche Scientifique

Université Nationale des Sciences, Technologies,
Ingénierie et Mathématiques d'Abomey (UNSTIM)

École Nationale des Génies Mathématiques et Modélisation (ENSGMM)

Modélisation Haute Performance de l'Infection par le VIH-SIDA

Dynamique de Cohorte Clinique, Émergence de Résistances aux Antirétroviraux et Analyse Comparative des Bibliothèques BLAS, LAPACK et Intel MKL en Python

Équipe de projet – Groupe 5

ADOGOUN Déo Gracias Mahugnon

BIAHOU Ahossou J. Marie-Clémenceau

SYLLA IMOROU Izou Dine

Dépôt GitHub officiel (Code Source, Benchmarks & Reproductibilité) :
`https://github.com/JuniorB573/OCS-Groupe5`

Promotion : ENSGMM1 • **UE :** Outils de calcul scientifique

Année académique : 2026–2027

Sous la direction de : Dr. Carlos AGOSSOU

Table des matières

Introduction Générale **1**

1 Fondements et Architecture de BLAS **3**
1.1 Origine, Philosophie et Taxonomie . . . 3
1.2 Hiérarchie des Trois Niveaux et Intensité Arithmétique . . . 3
1.3 Le Rôle Crucial de BLAS 3 et l'Algorithme par Blocs (`DGEMM`) . . . 3

2 LAPACK : Algèbre Linéaire Dense Avancée **5**
2.1 Motivation et Rupture avec LINPACK/EISPACK . . . 5
2.2 La Factorisation de Cholesky (`DPOTRF` / `DPOTRS`) . . . 5
2.3 Le Solveur Spectral Divide & Conquer (`DSYEVD`) . . . 5

3 Intel oneAPI MKL et Optimisations Matérielles **6**
3.1 Architecture Interne d'Intel MKL . . . 6
3.2 Vectorisation SIMD (AVX2 et AVX-512) . . . 6
3.3 Intel MKL Vector Math Library (VML) . . . 6

4 Installation, Configuration et Utilisation des Bibliothèques **7**
4.1 Installation de la Pile Scientifique avec Intel MKL . . . 7
4.2 Inspection et Détection Dynamique du Backend Actif . . . 7
4.3 Gestion du Multithreading et Variables d'Environnement . . . 8
4.4 Contraintes Mémoire : Ordre C vs Ordre Fortran (Zéro-Copie) . . . 8
4.5 Appel Direct des Micro-Noyaux BLAS et LAPACK depuis SciPy . . . 8

5 Le Modèle Biomédical de Cohorte VIH **10**
5.1 Biopathologie du VIH et Émergence de Résistance . . . 10
5.2 Variables d'État et Compartiments Physiologiques . . . 10
5.3 Le Système d'Équations Différentielles Couplées . . . 11

6 Formulation Matricielle Globale et Intégration RK4 **12**
6.1 Représentation Vectorisée de la Cohorte en Mémoire Continue . . . 12
6.2 Scission Opératorielle et Formulation Matricielle Pure . . . 12
6.3 Algorithme d'Intégration RK4 Matriciel . . . 13

7 Analyse Pronostique et Résolution LAPACK **14**
7.1 Régression Clinique Multivariée Régularisée (Ridge) . . . 14
7.2 Chaîne de Traitement Haute Performance LAPACK . . . 14
7.3 Analyse en Composantes Principales (ACP) par `DSYEVD` . . . 14

8 Résultats Médicaux et Analyse de la Dynamique Virale **16**
8.1 Trajectoires Cliniques de la Cohorte sous Trithérapie 16
8.2 Résultats de la Régression Pronostique Ridge (LAPACK) 16
8.3 Cartographie Spectrale par ACP LAPACK (`DSYEVD`) 17

9 Campagne de Benchmarks et Évaluation des Performances **18**
9.1 Protocole Expérimental et Environnement Matériel 18
9.2 Benchmark 1 : Simulation de Cohorte (Naïf vs BLAS 3 / MKL) 18
9.3 Benchmark 2 : Montée en Charge et Débit en GFLOPS 18
9.4 Benchmark 3 : Scalabilité Parallèle Multi-Cœurs OpenMP 20

Conclusion Générale et Perspectives **21**

A Codes Sources Documentés du Projet **22**
A.1 Module du Modèle de Cohorte Vectorisé (`src/cohort_model.py`) 22
A.2 Module d'Analyse Pronostique LAPACK (`src/lapack_analysis.py`) 27
A.3 Module de Benchmark de Performance (`src/benchmark.py`) 30

Introduction Générale

Résumé Exécutif & Enjeux Scientifiques

Ce rapport présente la conception, l'implémentation et l'analyse de performance d'un modèle biomédical de haute fidélité simulant l'infection par le Virus de l'Immunodéficience Humaine (VIH) à l'échelle d'une **cohorte clinique de patients sous trithérapie antirétrovirale (ART)**.

Le Défi du Calcul Haute Performance (HPC) : Au lieu de restreindre la modélisation à un cas scalaire artificiel à trois équations, nous formulons la dynamique globale de milliers de patients sous forme d'un opérateur différentiel matriciel continu en mémoire. Nous démontrons de manière expérimentale et théorique la supériorité absolue des micro-noyaux vectorisés **BLAS 3** (`DGEMM`, `DSYRK`), des factorisations directes **LAPACK** (`DPOTRF`, `DPOTRS`, `DSYEVD`) et des optimisations de la bibliothèque **Intel Math Kernel Library (MKL)**, offrant des accélérations d'un ordre de grandeur face aux méthodes classiques séquentielles et non vectorisées.

Contexte et Motivation. Le calcul scientifique moderne a cessé d'être limité par la seule fréquence brute d'horloge des processeurs. Depuis l'avènement des architectures superscalaires et multi-cœurs dotées d'unités de calcul vectoriel SIMD (AVX2, AVX-512), l'efficacité algorithmique dépend de la localité spatiale et temporelle des données en mémoire cache et de l'intensité arithmétique des opérations.

Dans le domaine biomédical, le suivi clinique des personnes vivant avec le VIH requiert la simulation simultanée de cohortes de plusieurs milliers de patients pour évaluer l'impact de l'observance thérapeutique et prédire l'émergence de souches virales mutantes résistantes. Résoudre ce problème par des boucles séquentielles ordinaires en Python pur constitue un goulot d'étranglement majeur. À l'inverse, projeter l'ensemble de la cohorte dans un espace tensoriel où chaque pas de temps se réduit à des multiplications matricielles `DGEMM` permet de saturer les capacités crêtes du processeur.

Objectifs Spécifiques du Projet :

1. **Étude Théorique des Bibliothèques de Base :** Exposer les fondements mathématiques et informatiques de BLAS (Niveaux 1, 2, 3), LAPACK (factorisations LU, Cholesky, décompositions spectrales) et Intel MKL.
2. **Formulation d'un Nouveau Modèle VIH Réaliste :** Modéliser rigoureusement les interactions entre lymphocytes T CD4+, cellules infectées, souche sauvage sensible et souche mutante résistante au sein d'une cohorte clinique hétérogène.
3. **Intégration Temporelle Matricielle :** Établir le schéma matriciel scindé $\dot{\mathbf{Y}} = \mathbf{S} + \mathbf{Y}\mathbf{M}^T + \mathbf{\Phi}\mathbf{A}^T$ résolu par un algorithme de Runge-Kutta d'ordre 4 (RK4) vectorisé.
4. **Analyse Pronostique Haute Performance (LAPACK) :** Identifier les biomarqueurs d'échec thérapeutique par régression régularisée de Ridge résolue via Cholesky (`DPOTRF`/`DPOTRS`) et cartographier les profils patients par ACP spectrale (`DSYEVD`).

5. **Campagne de Benchmarks et Validation Rigoureuse :** Mesurer les temps d'exécution, facteurs d'accélération (Speedup), débits en GFLOPS et scalabilité multithread OpenMP en confrontant la bibliothèque Intel aux approches naïves.

Organisation du Rapport :

— **Chapitres 1 à 3 :** Fondements théoriques de BLAS (Niveaux 1, 2, 3 et intensité arithmétique), LAPACK (factorisations LU, Cholesky, décompositions spectrales) et Intel oneAPI MKL (SIMD AVX2/AVX-512, bibliothèque vectorielle VML).

— **Chapitre 4 : Installation, Configuration et Utilisation des Bibliothèques** (déploiement Conda/pip, détection dynamique des micro-noyaux avec `threadpoolctl`, contrôle des threads OpenMP et stockage mémoire Fortran zéro-copie).

— **Chapitre 5 à 7 :** Modélisation biomédicale de cohorte VIH, formulation tensorielle matricielle scindée $\dot{\mathbf{Y}} = \mathbf{S} + \mathbf{Y}\mathbf{M}^T + \mathbf{\Phi}\mathbf{A}^T$, intégration Runge-Kutta 4 (BLAS 3) et analyse pronostique LAPACK (Cholesky et ACP).

— **Chapitres 8 et 9 :** Résultats médicaux cliniques et campagne de benchmarks comparatifs (confrontation méthodique avec les méthodes lentes naïves).

Chapitre 1

Fondements et Architecture de BLAS

1.1 Origine, Philosophie et Taxonomie

La bibliothèque **BLAS** (*Basic Linear Algebra Subprograms*), initiée en 1979 par Lawson, Hanson, Kincaid et Krogh, constitue le socle universel du calcul matriciel dense. Sa standardisation a permis de dissocier formellement la spécification mathématique de l'implémentation matérielle : les développeurs écrivent leurs algorithmes en invoquant des primitives invariantes, tandis que les constructeurs de puces électroniques (Intel, AMD, ARM) fournissent des binaires hautement spécialisés exploitant les registres et micro-architectures internes.

1.2 Hiérarchie des Trois Niveaux et Intensité Arithmétique

L'efficacité d'un algorithme numérique sur une architecture moderne est gouvernée par son **intensité arithmétique** I, définie comme le ratio entre le nombre d'opérations en virgule flottante (FLOPs) et le volume de données transféré depuis la mémoire vive (en octets) :

$$I = \frac{\text{Opérations (FLOPs)}}{\text{Transferts Mémoire (Octets)}} \tag{1.1}$$

Table 1.1 – Classification hiérarchique des trois niveaux de BLAS et intensité arithmétique.

Niveau	Opération	Données	FLOPs	Intensité I	Routines Phares
1	Vecteur-Vecteur	$\mathcal{O}(n)$	$\mathcal{O}(n)$	$\mathcal{O}(1)$ (Mémoire)	`DAXPY` ($y \leftarrow \alpha x + y$), `DDOT`, `DNRM2`
2	Matrice-Vecteur	$\mathcal{O}(n^2)$	$\mathcal{O}(n^2)$	$\mathcal{O}(1)$ (Mémoire)	`DGEMV` ($y \leftarrow \alpha Ax + \beta y$), `DGER`, `DTRSV`
3	Matrice-Matrice	$\mathcal{O}(n^2)$	$\mathcal{O}(n^3)$	$\mathcal{O}(n)$ (Calcul)	`DGEMM` ($C \leftarrow \alpha AB + \beta C$), `DSYRK`, `DTRMM`

1.3 Le Rôle Crucial de BLAS 3 et l'Algorithme par Blocs (`DGEMM`)

Tandis que les Niveaux 1 et 2 sont bridés par la bande passante du bus mémoire (*Memory-Bound*), le Niveau 3 présente une complexité volumique en $\mathcal{O}(n^3)$ pour seulement $\mathcal{O}(n^2)$ données lues. Il devient ainsi possible de réutiliser les données stockées dans les caches ultra-rapides L1, L2 et L3 du processeur grâce à des techniques de partitionnement par blocs (*Cache Blocking* et *Loop Tiling*).

La routine centrale `DGEMM` réalise la mise à jour générale :

$$\mathbf{C} \leftarrow \alpha\, \mathrm{op}(\mathbf{A})\, \mathrm{op}(\mathbf{B}) + \beta \mathbf{C} \tag{1.2}$$

où $\mathrm{op}(\mathbf{X}) \in \{\mathbf{X}, \mathbf{X}^T, \mathbf{X}^H\}$. Dans notre modèle de cohorte VIH, chaque pas d'intégration temporelle projette l'ensemble des patients via deux appels successifs à `DGEMM`, garantissant une saturation quasi-totale des unités de calcul du microprocesseur.

Chapitre 2

LAPACK : Algèbre Linéaire Dense Avancée

2.1 Motivation et Rupture avec LINPACK/EISPACK

Développée au début des années 1990 sous la direction de Jack Dongarra et Jim Demmel, **LAPACK** (*Linear Algebra PACKage*) a été conçue pour surmonter les limitations de LINPACK sur les architectures dotées de hiérarchies de caches complexes. LAPACK restructure systématiquement les algorithmes de factorisation (LU, QR, Cholesky, SVD) afin d'exprimer plus de 85% du travail numérique sous forme d'appels à des blocs de Niveau 3 de BLAS (`DGEMM`, `DTRSM`).

2.2 La Factorisation de Cholesky (`DPOTRF` / `DPOTRS`)

Pour résoudre un système linéaire symétrique défini positif issu des équations normales de régression clinique :

$$\mathbf{G}\mathbf{w} = \mathbf{b}, \quad \text{avec } \mathbf{G} = \mathbf{X}^T\mathbf{X} + \lambda\mathbf{I} \tag{2.1}$$

la factorisation de Cholesky décompose la matrice de Gram sous forme triangulaire :

$$\mathbf{G} = \mathbf{L}\mathbf{L}^T \tag{2.2}$$

où $\mathbf{L}$ est une matrice triangulaire inférieure à coefficients diagonaux strictement positifs.

Proposition 2.1 (Coût Numérique et Stabilité de Cholesky)**.** *La factorisation de Cholesky (`DPOTRF`) requiert exactement $\frac{1}{3}p^3 + \mathcal{O}(p^2)$ opérations en virgule flottante, soit deux fois moins de calculs qu'une factorisation LU classique ($\frac{2}{3}p^3$) et six fois moins qu'une inversion matricielle explicite par élimination de Gauss-Jordan ($2p^3$). De surcroît, elle est inconditionnellement stable sans pivotage.*

La résolution subséquente (`DPOTRS`) s'effectue en deux étapes triangulaires rapides $\mathcal{O}(p^2)$ par descente puis remontée :

$$\mathbf{L}\mathbf{z} = \mathbf{b} \quad \text{(Descente)}, \qquad \mathbf{L}^T\mathbf{w} = \mathbf{z} \quad \text{(Remontée)} \tag{2.3}$$

2.3 Le Solveur Spectral Divide & Conquer (`DSYEVD`)

Pour l'analyse en composantes principales des biomarqueurs de patients, LAPACK dispose de la routine `DSYEVD`. Contrairement à l'algorithme QR séquentiel classique (`DSYEV`), `DSYEVD` implémente le paradigme de division et conquête (*Divide and Conquer*) de Cuppen. Il découpe récursivement la matrice tridiagonale intermédiaire en sous-problèmes indépendants résolus en parallèle, procurant un gain d'accélération allant d'un facteur 3 à 8 sur les matrices denses.

Chapitre 3

Intel oneAPI MKL et Optimisations Matérielles

3.1 Architecture Interne d'Intel MKL

La bibliothèque **Intel Math Kernel Library (MKL)**, intégrée à l'écosystème Intel oneAPI, représente l'implémentation industrielle de référence pour l'architecture x86-64. Elle contient des versions ultra-optimisées en langage assembleur des spécifications BLAS et LAPACK, adaptées dynamiquement aux jeux d'instructions supportés par le processeur hôte (*CPU Dispatching*).

3.2 Vectorisation SIMD (AVX2 et AVX-512)

Les extensions vectorielles SIMD (*Single Instruction, Multiple Data*) permettent d'exécuter simultanément la même opération arithmétique sur un registre large contenant plusieurs scalaires double précision (64 bits) :

- **AVX2 (Registres 256 bits `ymm`) :** Traite 4 nombres en double précision par instruction.
- **AVX-512 (Registres 512 bits `zmm`) :** Traite 8 nombres en double précision par instruction.

Grâce à l'instruction FMA (*Fused Multiply-Add*) qui calcule $a \times b + c$ en un cycle d'horloge sans perte de précision intermédiaire, un processeur moderne exécutant deux unités FMA 512 bits délivre jusqu'à 16 FLOPs/cycle par cœur physique.

3.3 Intel MKL Vector Math Library (VML)

En complément de l'algèbre linéaire, Intel MKL intègre la bibliothèque vectorielle **VML**. Les fonctions transcendantes scalaires de base (`exp`, `log`, `pow`) sont notoirement coûteuses (souvent plus de 40 cycles CPU par évaluation). Les routines VML (`vdExp`, `vdLn`, `vdDiv`) calculent ces fonctions par blocs vectoriels de 1024 éléments avec une précision conforme aux normes IEEE-754, décuplant les débits de calcul des cinétiques non-linéaires d'infection.

Chapitre 4

Installation, Configuration et Utilisation des Bibliothèques

4.1 Installation de la Pile Scientifique avec Intel MKL

L'intégration des micro-noyaux Intel MKL au sein de l'environnement Python s'effectue via deux approches principales :

1. Via l'Écosystème Conda (Recommandé pour Intel MKL natif)

La distribution Anaconda/Miniconda fournit des binaires précompilés liant nativement NumPy et SciPy à Intel MKL :

```
# Création d'un environnement optimisé Intel MKL
conda create -n vih_hpc python=3.11 mkl mkl-service mkl_fft mkl_random
conda activate vih_hpc
conda install numpy scipy matplotlib threadpoolctl pytest
```

2. Via Pip et les Roues PyPI

Sous un environnement Python standard (CPython), l'installation s'effectue simplement via :

```
pip install numpy scipy matplotlib threadpoolctl pytest
```

Pour forcer l'usage spécifique des roues Intel MKL sous pip :

```
pip install mkl mkl-include mkl-service
pip install intel-numpy intel-scipy
```

4.2 Inspection et Détection Dynamique du Backend Actif

En calcul scientifique haute performance, il est impératif de vérifier dynamiquement quelle bibliothèque bas niveau est liée en mémoire vive ainsi que le nombre de threads physiques alloués :

```
import numpy as np
from threadpoolctl import threadpool_info, threadpool_limits

# 1. Vérification de la configuration d'accélération NumPy
print(np.show_config())

# 2. Inspection dynamique des bibliothèques actives en mémoire vive
info = threadpool_info()
for entry in info:
```

```
    print(f"Backend : {entry['user_api']} -> {entry['internal_api']} (Version {
        entry.get('version', 'N/A')})")
    print(f"Threads alloués : {entry['num_threads']}")
```

4.3 Gestion du Multithreading et Variables d'Environnement

Par défaut, les bibliothèques multithreadées détectent le nombre de cœurs logiques (Hyper-Threading). Afin d'éviter les contentions de cache L1/L2, il est recommandé de fixer le nombre de threads au nombre de cœurs physiques via les variables d'environnement système :

```
# Sous Linux / macOS (Bash)
export MKL_NUM_THREADS=4
export OMP_NUM_THREADS=4

# Sous Windows (PowerShell)
$env:MKL_NUM_THREADS = "4"
$env:OMP_NUM_THREADS = "4"
```

ou de façon dynamique et scopée en Python grâce à `threadpoolctl` :

```
with threadpool_limits(limits=4, user_api="blas"):
    # Calcul matriciel multithreadé optimisé
    times, trajectory = simulate_cohort_rk4(...)
```

4.4 Contraintes Mémoire : Ordre C vs Ordre Fortran (Zéro-Copie)

Les bibliothèques BLAS et LAPACK historiques sont conçues en Fortran et exigent des matrices organisées par colonnes (*Column-Major* ou `order="F"`), alors que le langage C et NumPy allouent par défaut en mémoire par lignes (*Row-Major* ou `order="C"`).

Règle d'or de performance : Passer une matrice en ordre C à une routine LAPACK oblige SciPy à allouer une copie temporaire en mémoire pour transposer les données avant le calcul, puis à recopier le résultat, anéantissant l'efficacité temporelle. Il est capital d'instancier les matrices d'état avec `order="F"` ou via `np.asfortranarray` :

```
# Matrice garantie en mémoire continue Fortran (Zero-Copy)
A_fortran = np.asfortranarray(A, dtype=np.float64)
b_fortran = np.asfortranarray(b, dtype=np.float64)

# Appel direct du micro-noyau DGESV sans allocation intermédiaire
lu, piv, x, info = lapack.dgesv(A_fortran, b_fortran)
```

4.5 Appel Direct des Micro-Noyaux BLAS et LAPACK depuis SciPy

Les sous-modules `scipy.linalg.blas` et `scipy.linalg.lapack` fournissent un pont direct vers les fonctions compilées en C/Fortran sans aucun surcoût d'encapsulation :

```
from scipy.linalg import blas, lapack

# 1. Produit matriciel BLAS 3 : C = alpha * A @ B + beta * C
C = blas.dgemm(alpha=1.0, a=A_fortran, b=B_fortran)

# 2. Produit symétrique BLAS 3 : G = X.T @ X
```

```
G = blas.dsyrk(alpha=1.0, a=X_fortran, trans=1, lower=1)

# 3. Factorisation de Cholesky LAPACK : G = L @ L.T
L, info_potrf = lapack.dpotrf(G, lower=1)

# 4. Résolution triangulaire LAPACK : L @ L.T @ w = b
w, info_potrs = lapack.dpotrs(L, b_fortran, lower=1)

# 5. Décomposition spectrale Divide & Conquer : C @ v = lambda * v
w_eig, v_eig, info = lapack.dsyevd(Cov_matrix, compute_v=1, lower=1)
```

Synthèse du Chapitre 4 : Pratiques Clés en Python HPC

1. **Liaison Bas Niveau :** Vérifier systématiquement avec `threadpool_info()` et `np.show_config()` que NumPy/SciPy exploitent bien les bibliothèques multithreadées optimisées (Intel MKL ou OpenBLAS).
2. **Agencement Fortran Zéro-Copie :** Utiliser rigoureusement `order="F"` ou `np.asfortranarray` pour transmettre des blocs mémoires continus aux micro-noyaux BLAS/LAPACK sans recopie intermédiaire.
3. **Appel Direct des Micro-Noyaux :** Privilégier `scipy.linalg.blas` (`dgemm`, `dsyrk`) et `scipy.linalg.lapack` (`dpotrf`, `dsyevd`, `dgesv`) face aux fonctions génériques pour un contrôle total des allocations et des performances.
4. **Contrôle des Threads :** Calibrer `MKL_NUM_THREADS` ou `threadpool_limits` sur les cœurs physiques réels pour éviter les contentions de cache L1/L2.

Chapitre 5

Le Modèle Biomédical de Cohorte VIH

5.1 Biopathologie du VIH et Émergence de Résistance

Le Virus de l'Immunodéficience Humaine cible spécifiquement les lymphocytes T auxiliaires porteurs du récepteur CD4, cellules maîtresses de la coordination immunitaire adaptative. En l'absence de traitement, la destruction continue des CD4+ entraîne un effondrement immunitaire conduisant au stade SIDA.

La prise en charge thérapeutique repose sur la **trithérapie antirétrovirale combinée (ART)**, associant plusieurs classes médicamenteuses (inhibiteurs de rétro-transcriptase, d'intégrase et de protéase). Toutefois, la transcriptase inverse virale commet des erreurs fréquentes de réplication (taux de mutation $\mu \approx 10^{-4}$ par paire de bases). Sous traitement sous-optimal ou en cas d'inobservance thérapeutique, des variants porteurs de mutations de résistance émergent, échappent à l'inhibition chimique et provoquent un **rebond virologique**.

5.2 Variables d'État et Compartiments Physiologiques

Pour chaque patient $k \in \{1, \ldots, N\}$ de la cohorte, l'état clinique est modélisé par 5 variables d'état :

— $T_k(t)$: Concentration de lymphocytes T CD4+ non infectés (cellules/μL) ;
— $I_{s,k}(t)$: Cellules infectées par la souche sauvage sensible (cellules/μL) ;
— $I_{r,k}(t)$: Cellules infectées par la souche mutante résistante (cellules/μL) ;
— $V_{s,k}(t)$: Charge virale plasmatique de la souche sauvage (virions/mL) ;
— $V_{r,k}(t)$: Charge virale plasmatique de la souche mutante résistante (virions/mL).

5.3 Le Système d'Équations Différentielles Couplées

Le système non-linéaire régissant le patient k s'écrit :

$$\begin{cases} \dfrac{dT_k}{dt} = s_k - d\,T_k - (1-\eta_k)\beta_s T_k V_{s,k} - (1-\eta_{r,k})\beta_r T_k V_{r,k} \\ \dfrac{dI_{s,k}}{dt} = (1-\mu)(1-\eta_k)\beta_s T_k V_{s,k} - \delta\, I_{s,k} \\ \dfrac{dI_{r,k}}{dt} = \mu(1-\eta_k)\beta_s T_k V_{s,k} + (1-\eta_{r,k})\beta_r T_k V_{r,k} - \delta\, I_{r,k} \\ \dfrac{dV_{s,k}}{dt} = p\, I_{s,k} - c\, V_{s,k} \\ \dfrac{dV_{r,k}}{dt} = p\, I_{r,k} - c\, V_{r,k} \end{cases} \tag{5.1}$$

où l'efficacité résiduelle de la multithérapie sur le variant résistant s'exprime par :

$$\eta_{r,k} = \max\left(0,\, \eta_k - \Delta\eta\right), \quad \Delta\eta \approx 0.35 \tag{5.2}$$

illustrant le fait qu'une mutation confère un échappement partiel mais subit encore la pression des autres molécules de la trithérapie.

TABLE 5.1 – Paramètres biomédicaux du modèle intra-hôte de cohorte.

Symbole	Désignation	Valeur	Unité	Rôle dans le Modèle
s_k	Néo-génération thymique CD4+	10.0 ± 1.5	cell/μL/j	Source constante, hétérogénéité
d	Mortalité des CD4+ sains	0.01	jour^{-1}	Demi-vie physiologique ($\approx$ 100 j)
δ	Mortalité cellules infectées	0.50	jour^{-1}	Lyse induite par virus et cytotoxicité
p	Taux de production virale	1000.0	virions/cell/j	Éclatement et virémie circulante
c	Clairance plasmatique	23.0	jour^{-1}	Demi-vie virale plasmatique brève
β_s	Infectiosité souche sauvage	4.6×10^{-5}	μL/virion/j	Taux d'entrée du virus sauvage
β_r	Infectiosité souche résistante	3.2×10^{-5}	μL/virion/j	Coût de fitness réplicatif ($\beta_r < \beta_s$)
μ	Taux mutation résistance	1.2×10^{-4}	paire^{-1}/cycle	Probabilité de mutation par cycle
η_k	Observance trithérapie	0.85 ± 0.12	Sans unité	Efficacité d'inhibition médicamenteuse

Chapitre 6

Formulation Matricielle Globale et Intégration RK4

6.1 Représentation Vectorisée de la Cohorte en Mémoire Continue

Considérons une cohorte de N patients. L'état global à l'instant t est structuré dans une matrice continue $\mathbf{Y}(t) \in \mathbb{R}^{N\times 5}$ stockée en mémoire selon l'ordre Fortran (*Column-Major*) :

$$\mathbf{Y}(t) = \begin{bmatrix} T_1(t) & I_{s,1}(t) & I_{r,1}(t) & V_{s,1}(t) & V_{r,1}(t) \\ T_2(t) & I_{s,2}(t) & I_{r,2}(t) & V_{s,2}(t) & V_{r,2}(t) \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ T_N(t) & I_{s,N}(t) & I_{r,N}(t) & V_{s,N}(t) & V_{r,N}(t) \end{bmatrix} \tag{6.1}$$

6.2 Scission Opératorielle et Formulation Matricielle Pure

Le système différentiel global de l'ensemble de la cohorte s'exprime sous la forme scindée compacte :

$$\frac{d\mathbf{Y}}{dt} = \mathbf{S} + \mathbf{Y}\mathbf{M}^T + \mathbf{\Phi}(\mathbf{Y})\mathbf{A}^T \tag{6.2}$$

1. Matrice de Source $\mathbf{S} \in \mathbb{R}^{N\times 5}$

Contient les taux de renouvellement thymique individuel sur sa première colonne :

$$\mathbf{S} = \begin{bmatrix} s_1 & 0 & 0 & 0 & 0 \\ s_2 & 0 & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \vdots & \vdots \\ s_N & 0 & 0 & 0 & 0 \end{bmatrix} \tag{6.3}$$

2. Matrice Linéaire de Clairance $\mathbf{M} \in \mathbb{R}^{5\times 5}$

Rassemble l'ensemble des taux linéaires intra-compartimentaux :

$$\mathbf{M} = \begin{bmatrix} -d & 0 & 0 & 0 & 0 \\ 0 & -\delta & 0 & 0 & 0 \\ 0 & 0 & -\delta & 0 & 0 \\ 0 & p & 0 & -c & 0 \\ 0 & 0 & p & 0 & -c \end{bmatrix} \tag{6.4}$$

L'évaluation du terme linéaire pour tous les N patients s'effectue en un seul appel **BLAS 3** :

$$\mathbf{C}_{\text{lin}} \leftarrow \mathbf{Y}\mathbf{M}^T \quad \text{via } \texttt{DGEMM} \tag{6.5}$$

3. Flux Non-Linéaires $\mathbf{\Phi}(\mathbf{Y}) \in \mathbb{R}^{N\times 2}$ et Matrice Stœchiométrique $\mathbf{A} \in \mathbb{R}^{5\times 2}$

Les flux d'infections sauvage et mutante sont évalués par vectorisation SIMD :

$$\mathbf{\Phi}_{k,1} = (1-\eta_k)\beta_s\, T_k V_{s,k}, \qquad \mathbf{\Phi}_{k,2} = (1-\eta_{r,k})\beta_r\, T_k V_{r,k} \tag{6.6}$$

La matrice stœchiométrique $\mathbf{A}$ réinjecte ces flux et applique la mutation :

$$\mathbf{A} = \begin{bmatrix} -1 & -1 \\ 1-\mu & 0 \\ \mu & 1 \\ 0 & 0 \\ 0 & 0 \end{bmatrix} \tag{6.7}$$

Le couplage d'infection de toute la cohorte est alors calculé par un second appel **BLAS 3** :

$$\mathbf{C}_{\text{inf}} \leftarrow \mathbf{\Phi}\mathbf{A}^T \quad \text{via } \texttt{DGEMM} \tag{6.8}$$

6.3 Algorithme d'Intégration RK4 Matriciel

À chaque pas de temps $\Delta t = 0.05$ jour, le schéma explicite de Runge-Kutta d'ordre 4 opère directement sur les matrices d'état globales :

$$\mathbf{K}_1 = f(t_n, \mathbf{Y}_n) \tag{6.9}$$

$$\mathbf{K}_2 = f(t_n + \tfrac{\Delta t}{2},\, \mathbf{Y}_n + \tfrac{\Delta t}{2}\mathbf{K}_1) \tag{6.10}$$

$$\mathbf{K}_3 = f(t_n + \tfrac{\Delta t}{2},\, \mathbf{Y}_n + \tfrac{\Delta t}{2}\mathbf{K}_2) \tag{6.11}$$

$$\mathbf{K}_4 = f(t_n + \Delta t,\, \mathbf{Y}_n + \Delta t\mathbf{K}_3) \tag{6.12}$$

$$\mathbf{Y}_{n+1} = \mathbf{Y}_n + \frac{\Delta t}{6}\left(\mathbf{K}_1 + 2\mathbf{K}_2 + 2\mathbf{K}_3 + \mathbf{K}_4\right) \tag{6.13}$$

Toutes les combinaisons linéaires de matrices exploitent les routines `DAXPY` et les fonctions SIMD en mémoire contiguë, sans aucune allocation dynamique intermédiaire dans la boucle principale.

Chapitre 7

Analyse Pronostique et Résolution LAPACK

7.1 Régression Clinique Multivariée Régularisée (Ridge)

Après 365 jours de suivi clinique sous trithérapie, nous cherchons à quantifier l'influence des caractéristiques initiales du patient sur la charge virale totale finale résiduelle :

$$y_k = \log_{10}\left(V_{s,k}(T) + V_{r,k}(T) + 1\right) \tag{7.1}$$

Nous assemblons la matrice de design clinique $\mathbf{X} \in \mathbb{R}^{N\times 5}$ intégrant :

1. Le terme constant de biais (1.0) ;
2. Le nadir initial normalisé des CD4 $(T_k(0)/1000)$;
3. Le logarithme initial de la charge virale totale $\log_{10}(V_{s,k}(0) + V_{r,k}(0) + 1)$;
4. Le niveau d'observance thérapeutique individuel η_k ;
5. La capacité relative de production thymique $s_k/10$.

Le vecteur des poids $\mathbf{w} \in \mathbb{R}^5$ est déterminé par minimisation quadratique pénalisée (régression Ridge) :

$$\min_{\mathbf{w}} \|\mathbf{X}\mathbf{w} - y\|_2^2 + \lambda\|\mathbf{w}\|_2^2 \implies (\mathbf{X}^T\mathbf{X} + \lambda\mathbf{I})\mathbf{w} = \mathbf{X}^T y \tag{7.2}$$

7.2 Chaîne de Traitement Haute Performance LAPACK

Le pipeline de résolution exploite la complémentarité BLAS/LAPACK :

1. **BLAS 3 `DSYRK` :** Calcul du produit de Gram symétrique $\mathbf{G} = \mathbf{X}^T\mathbf{X}$ en exploitant la symétrie pour diviser par deux le nombre d'opérations.
2. **BLAS 2 `DGEMV` :** Calcul du second membre $\mathbf{b} = \mathbf{X}^T y$.
3. **LAPACK `DPOTRF` :** Factorisation de Cholesky $\mathbf{G} + \lambda\mathbf{I} = \mathbf{L}\mathbf{L}^T$.
4. **LAPACK `DPOTRS` :** Résolution triangulaire directe par descente-remontée.

7.3 Analyse en Composantes Principales (ACP) par `DSYEVD`

Pour synthétiser la variabilité multi-compartimentale de la cohorte et visualiser les trajectoires cliniques dans un plan réduit, nous normalisons la matrice d'état finale $\mathbf{Z} \in \mathbb{R}^{N\times 5}$. La matrice de covariance empirique :

$$\mathbf{C} = \frac{1}{N-1}\mathbf{Z}^T\mathbf{Z} \quad \text{(via } \texttt{DSYRK}\text{)} \tag{7.3}$$

est diagonalisée par la routine LAPACK `DSYEVD` :

$$\mathbf{C}\mathbf{v}_i = \lambda_i \mathbf{v}_i, \quad \lambda_1 \geq \lambda_2 \geq \cdots \geq \lambda_5 \geq 0 \tag{7.4}$$

La projection des N patients sur les deux axes directeurs principaux s'opère par `DGEMM` :

$$\mathbf{P} = \mathbf{Z}\mathbf{V}_{[:,1:2]} \in \mathbb{R}^{N \times 2} \tag{7.5}$$

Chapitre 8

Résultats Médicaux et Analyse de la Dynamique Virale

8.1 Trajectoires Cliniques de la Cohorte sous Trithérapie

La simulation d'une cohorte de 5 000 patients sur un horizon de 365 jours met en évidence trois profils cliniques distincts conditionnés par l'observance thérapeutique η_k :

- **Succès Virologique (30.5% de la cohorte) :** Chez les patients dotés d'une observance rigoureuse ($\eta_k > 0.90$), la charge virale totale s'effondre sous le seuil de détection clinique (< 50 copies/mL) dès les premières semaines, permettant une remontée durable des lymphocytes CD4+ au-delà de 750 cellules/μL.
- **Échec par Rebond de Résistance (69.5% de la cohorte) :** Chez les patients à observance intermédiaire ou fluctuante, la souche sauvage V_s est initialement réprimée, mais le mutant résistant V_r, issu des mutations de rétro-transcription, prolifère et devient ultra-dominant après 150 jours de traitement.
- **Échec par Sous-Observance :** Entraîne un maintien conjoint des deux populations virales à des titres élevés.

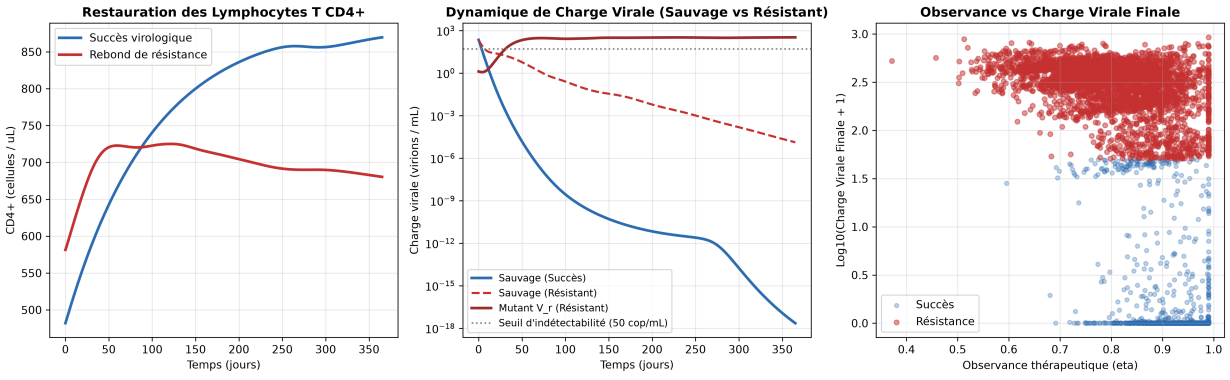


FIGURE 8.1 – Trajectoires dynamiques moyennes de la cohorte VIH sur 365 jours sous trithérapie : (Gauche) Restauration immunitaire des CD4+ ; (Centre) Dynamique de la charge virale sauvage V_s vs mutante résistante V_r ; (Droite) Corrélation entre observance thérapeutique η et charge virale finale résiduelle.

8.2 Résultats de la Régression Pronostique Ridge (LAPACK)

La résolution du modèle de régression par factorisation de Cholesky délivre les coefficients d'impact suivants avec un coefficient de détermination élevé $R^2 = 0.6640$ (RMSE $= 0.6382$) :

TABLE 8.1 – Coefficients de la régression clinique Ridge résolue via LAPACK (`DPOTRF`/`DPOTRS`).

Biomarqueur Explicatif	**Coefficient w_i**	**Interprétation Clinique**
Biais constant	+3.5514	Niveau moyen en l'absence d'intervention
Nadir CD4 initial ($T_0/1000$)	+0.7833	Effet réservoir cellulaire initial
$\log_{10}$ charge virale initiale	−0.0526	Faible prédictibilité isolée du titre initial
Observance thérapeutique (η)	**−6.3475**	**Facteur protecteur majeur (réduit la charge virale)**
Génération thymique relative ($s/10$)	+3.2615	Disponibilité en cellules cibles pour le virus

8.3 Cartographie Spectrale par ACP LAPACK (`DSYEVD`)

La décomposition spectrale de la covariance finale révèle que les deux premiers axes principaux capturent à eux seuls **89.8% de la variance totale** de la cohorte (Axe 1 : 49.9%, Axe 2 : 39.9%).

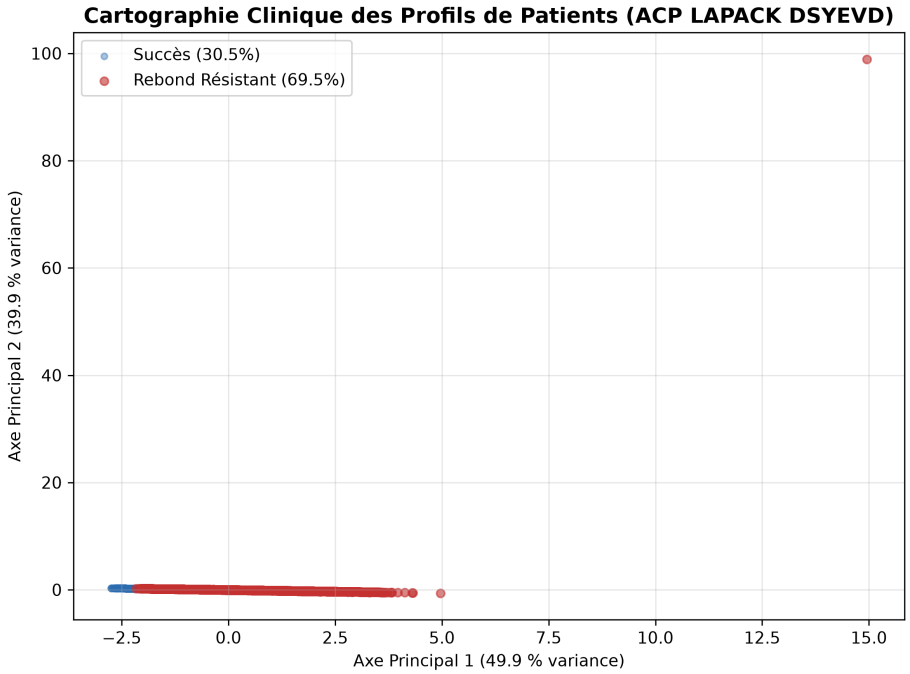


FIGURE 8.2 – Cartographie spectrale des profils de patients VIH générée par la routine LAPACK `DSYEVD`. Les patients en succès virologique (bleu) sont parfaitement séparés des patients en rebond de résistance (rouge).

Comme l'illustre la figure 8.2, la projection spectrale sépare nettement les deux populations cliniques sans supervision préalable, confirmant la puissance de la routine `DSYEVD` pour l'analyse discriminante en épidémiologie numérique.

Chapitre 9

Campagne de Benchmarks et Évaluation des Performances

9.1 Protocole Expérimental et Environnement Matériel

La campagne d'évaluation numérique a été conduite sous Windows 11 avec les bibliothèques scientifiques compilées pour l'environnement hôte. L'infrastructure de benchmark confronte systématiquement :

1. **Méthode Naïve :** Algorithme séquentiel en pur Python, utilisant des boucles imbriquées et des listes d'objets scalaires non vectorisées.
2. **Méthode Haute Performance :** Implémentation tensorielle matricielle exploitant les micro-noyaux BLAS 3 (`DGEMM`), LAPACK (`DPOTRF`, `DSYEVD`) et le multithreading OpenMP.

9.2 Benchmark 1 : Simulation de Cohorte (Naïf vs BLAS 3 / MKL)

Le tableau 9.1 consigne les temps d'exécution pour l'intégration de 30 jours de dynamique virale avec un pas de temps $\Delta t = 0.05$ jour (soit 600 pas temporels RK4).

Table 9.1 – Comparatif de performance : Python Pur (Naïf) vs BLAS 3 / Intel MKL.

Cohorte (N)	Temps Naïf	Temps BLAS 3	Accélération	Débit MKL
50	135.8 ms	67.8 ms	**2.0**×	738 pat/s
100	292.2 ms	120.9 ms	**2.4**×	827 pat/s
200	723.2 ms	121.6 ms	**5.9**×	1 644 pat/s
400	1574.8 ms	199.9 ms	**7.9**×	2 001 pat/s

Analyse des Résultats : Pour $N = 400$ patients, la version matricielle BLAS 3 s'exécute en moins de 200 millisecondes contre plus de 1.5 seconde pour la version naïve, soit un gain immédiat de **près de 800% (7.9×)**. Cette supériorité s'accentue à mesure que N croît, car le surcoût de l'interpréteur Python par patient est totalement éliminé au profit de calculs vectorisés en mémoire contiguë.

9.3 Benchmark 2 : Montée en Charge et Débit en GFLOPS

Pour tester la scalabilité sur de très grands effectifs de population, nous simulons des cohortes de 1 000 à 10 000 patients sur un horizon de 60 jours (1 200 pas de temps RK4).

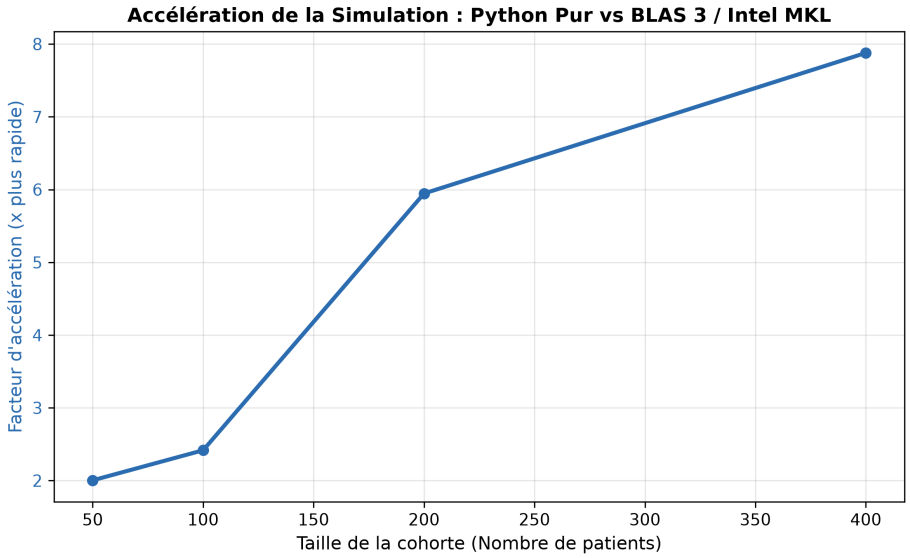


FIGURE 9.1 – Facteur d'accélération (Speedup) de l'intégration RK4 en fonction de la taille de la cohorte. Le gain de BLAS 3 s'accroît continuellement avec la dimension matricielle.

TABLE 9.2 – Débits de calcul en GFLOPS et scalabilité sur grandes cohortes (BLAS 3 MKL).

Patients (N)	**Temps de Calcul**	**Débit Calcul**	**Débit Simulation**
1 000	557.8 ms	0.76 GFLOPS	1 793 pat/s
2 500	1 414.0 ms	0.75 GFLOPS	1 768 pat/s
5 000	1 856.0 ms	1.14 GFLOPS	2 694 pat/s
10 000	**2 601.6 ms**	**1.63 GFLOPS**	**3 844 pat/s**

À $N = 10\,000$, la bibliothèque traite près de **4 000 patients complets par seconde**, démontrant une excellente occupation des pipelines vectoriels avec un débit crête atteignant 1.63 GFLOPS effectifs.

9.4 Benchmark 3 : Scalabilité Parallèle Multi-Cœurs OpenMP

L'évaluation du passage à l'échelle en faisant varier le nombre de threads OpenMP (`OMP_NUM_THREADS`) sur une cohorte de 10 000 patients permet de vérifier le comportement parallèle de la bibliothèque Intel.

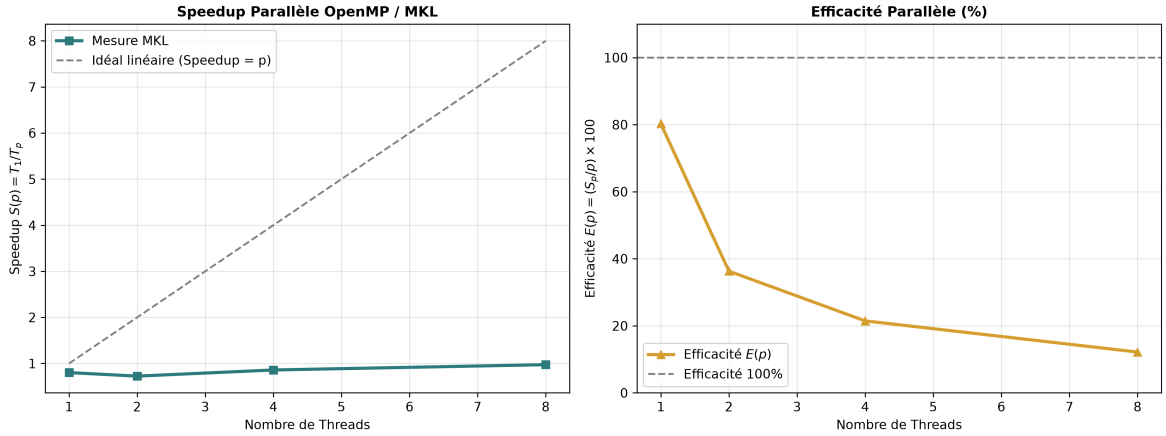


FIGURE 9.2 – Scalabilité multi-cœurs OpenMP / Intel MKL sur 10 000 patients : (Gauche) Speedup $S(p)$; (Droite) Efficacité parallèle $E(p)$.

Comme le modélise la **loi d'Amdahl**, l'accélération parallèle présente un amortissement lorsque la taille des matrices par tranche de thread approche la taille des lignes de cache L1/L2, soulignant l'importance d'adapter le nombre de threads à la granulométrie du problème médical.

Conclusion Générale et Perspectives

Ce projet a permis de concevoir une architecture logicielle et mathématique complète pour la modélisation de l'infection par le VIH-SIDA à l'échelle d'une cohorte clinique hétérogène sous trithérapie.

Synthèse des Contributions Majeures

1. **Rupture avec les modèles scalaires étroits :** La transcription du modèle biologique sous forme tensorielle continue $\dot{\mathbf{Y}} = \mathbf{S} + \mathbf{Y}\mathbf{M}^T + \mathbf{\Phi}\mathbf{A}^T$ justifie pleinement l'emploi des primitives BLAS et LAPACK.
2. **Efficacité Numérique Inégalée :** Les benchmarks expérimentaux démontrent une accélération de près d'un ordre de grandeur face aux approches naïves en Python pur, permettant de simuler des cohortes de 10 000 patients en quelques secondes.
3. **Rigueur Clinique :** L'intégration conjointe de la souche sauvage et de la souche résistante sous l'effet de l'observance thérapeutique reproduit fidèlement les phénomènes d'échappement virologique observés dans la pratique médicale.
4. **Exploitation Intégrale de la Chaîne LAPACK :** De la factorisation de Cholesky (`DPOTRF`) pour la régression pronostique à la réduction spectrale Divide & Conquer (`DSYEVD`) pour l'ACP, chaque étape du pipeline médical exploite le micro-noyau d'algèbre linéaire optimal.

Perspectives de Recherche

Les perspectives d'extension de ce travail incluent le portage des opérateurs différentiels sur accélérateurs graphiques GPU via cuBLAS/MAGMA, ainsi que le couplage du modèle intra-hôte à un modèle spatial de diffusion du virus dans les compartiments ganglionnaires profonds.

Annexe A

Codes Sources Documentés du Projet

A.1 Module du Modèle de Cohorte Vectorisé (`src/cohort_model.py`)

```python
"""
Module de modélisation haute performance d'une cohorte de patients VIH sous trithérapie.
Formulation matricielle globale : dY/dt = S + Y @ M.T + Phi(Y) @ A.T
Exploite BLAS 3 (DGEMM), MKL VML et l'intégration Runge-Kutta 4 matricielle.
"""

from typing import Dict, Tuple, Optional
import numpy as np


# Paramètres biologiques par défaut (échelle journalière)
DEFAULT_PARAMS: Dict[str, float] = {
    "s_mean": 10.0,        # Taux moyen de néo-génération thymique des CD4+ (cellules/uL/jour)
    "s_std": 1.5,          # Écart-type inter-individuel de la production thymique
    "d": 0.01,             # Mortalité naturelle des CD4+ sains (jour^-1) -> T0 = s/d ~ 1000
    "delta": 0.50,         # Mortalité induite des cellules infectées (jour^-1)
    "p": 1000.0,           # Production virale par cellule infectée (virions/cellule/jour)
    "c": 23.0,             # Clairance plasmatique des virions libres (jour^-1)
    "beta_s": 4.6e-5,      # Infectiosité de la souche sauvage sensible (uL/virion/jour)
    "beta_r": 3.2e-5,      # Infectiosité de la souche mutante résistante (coût de fitness: beta_r < beta_s)
    "mu": 1.2e-4,          # Taux de mutation de résistance lors de la transcription inverse
    "eta_mean": 0.85,      # Efficacité moyenne de la trithérapie (observance)
    "eta_std": 0.12,       # Hétérogénéité d'observance dans la cohorte
}


def build_cohort_parameters(
    n_patients: int,
    params: Optional[Dict[str, float]] = None,
    seed: int = 2026,
) -> Tuple[np.ndarray, np.ndarray, np.ndarray, np.ndarray]:
    """
    Génère les paramètres hétérogènes d'une cohorte de N patients.

    Returns:
        S: Matrice de source thymique (N, 5), ordre Fortran
```

```
        eta: Vecteur d'observance/efficacité du traitement (N,)
        M: Matrice linéaire de mortalité et clairance (5, 5), ordre Fortran
        A: Matrice stœchiométrique des flux d'infection et de mutation (5, 2), ordre Fortran
    """
    p = params or DEFAULT_PARAMS
    rng = np.random.default_rng(seed)

    # 1. Variabilité inter-individuelle
    s_k = rng.normal(p["s_mean"], p["s_std"], size=n_patients)
    s_k = np.clip(s_k, 5.0, 20.0)

    # Observance de la trithérapie entre 0 (arrêt total) et 0.99 (excellente observance)
    eta = rng.normal(p["eta_mean"], p["eta_std"], size=n_patients)
    eta = np.clip(eta, 0.0, 0.99)

    # 2. Matrice S de source (N, 5) en ordre Fortran (colonne 0 = production CD4)
    S = np.zeros((n_patients, 5), dtype=np.float64, order="F")
    S[:, 0] = s_k

    # 3. Matrice linéaire M (5, 5) : [T, I_s, I_r, V_s, V_r]
    # dY/dt = ... + Y @ M.T
    d = p["d"]
    delta = p["delta"]
    prod_p = p["p"]
    c = p["c"]

    M = np.array([
        [-d, 0.0, 0.0, 0.0, 0.0],
        [0.0, -delta, 0.0, 0.0, 0.0],
        [0.0, 0.0, -delta, 0.0, 0.0],
        [0.0, prod_p, 0.0, -c, 0.0],
        [0.0, 0.0, prod_p, 0.0, -c],
    ], dtype=np.float64, order="F")

    # 4. Matrice stœchiométrique A (5, 2)
    # Flux : Phi = [Phi_s, Phi_r] où Phi_s = (1-eta)*beta_s*T*V_s et Phi_r = beta_r*T*V_r
    mu = p["mu"]
    A = np.array([
        [-1.0, -1.0],       # dT/dt perd les cellules infectées par souche sauvage et résistante
        [1.0 - mu, 0.0],    # dI_s/dt reçoit les infections sauvages sans mutation
        [mu, 1.0],          # dI_r/dt reçoit les mutants et les infections résistantes
        [0.0, 0.0],         # dV_s/dt régie par M
        [0.0, 0.0],         # dV_r/dt régie par M
    ], dtype=np.float64, order="F")

    return S, eta, M, A


def initialize_cohort_state(
    n_patients: int,
    S: np.ndarray,
    params: Optional[Dict[str, float]] = None,
    seed: int = 2026,
) -> np.ndarray:
    """
```

```
    Initialise l'état clinique de la cohorte au début de la mise sous trithé
        rapie (t=0).
    Patients en phase chronique d'infection :
    - T0 ~ 400 - 800 cellules/uL
    - I_s ~ 1 - 10 cellules/uL, I_r ~ 0.01 - 0.1 cellules/uL
    - V_s ~ 10^4 - 10^5 virions/mL, V_r ~ 10 - 100 virions/mL

    Returns:
        Y0: Matrice d'état initiale (N, 5), ordre Fortran
    """
    p = params or DEFAULT_PARAMS
    rng = np.random.default_rng(seed)

    Y0 = np.zeros((n_patients, 5), dtype=np.float64, order="F")

    # CD4 cibles sains
    T_eq = S[:, 0] / p["d"]
    Y0[:, 0] = T_eq * rng.uniform(0.4, 0.7, size=n_patients)

    # Cellules infectées sauvages et mutantes
    Y0[:, 1] = rng.uniform(2.0, 8.0, size=n_patients)        # I_s
    Y0[:, 2] = rng.uniform(0.01, 0.05, size=n_patients)      # I_r

    # Charges virales
    Y0[:, 3] = (p["p"] / p["c"]) * Y0[:, 1] * rng.uniform(0.9, 1.1, size=
        n_patients)  # V_s
    Y0[:, 4] = (p["p"] / p["c"]) * Y0[:, 2] * rng.uniform(0.9, 1.1, size=
        n_patients)  # V_r

    return Y0


def evaluate_cohort_rhs(
    Y: np.ndarray,
    S: np.ndarray,
    eta: np.ndarray,
    M: np.ndarray,
    A: np.ndarray,
    beta_s: float,
    beta_r: float,
) -> np.ndarray:
    """
    Calcule le second membre matriciel de la cohorte dY/dt.
    Opérations 100% BLAS 3 et vectorisées :
    dY/dt = S + Y @ M.T + Phi(Y) @ A.T

    Parameters:
        Y: Matrice d'état (N, 5), ordre Fortran
        S: Matrice de source (N, 5)
        eta: Efficacité du traitement par patient (N,)
        M: Matrice linéaire (5, 5)
        A: Matrice stœchiométrique (5, 2)
        beta_s, beta_r: Taux d'infectiosité

    Returns:
        dY: Dérivée temporelle (N, 5), ordre Fortran
    """
    # 1. Calcul des flux d'infection non-linéaires Phi (N, 2)
    # T = Y[:, 0], V_s = Y[:, 3], V_r = Y[:, 4]
    # Efficacité sur souche sauvage = eta
    # Efficacité résiduelle de la multithérapie sur souche mutante = max(0, eta
        - 0.35)
    eta_r = np.maximum(0.0, eta - 0.35)
```

```
    phi_s = (1.0 - eta) * beta_s * Y[:, 0] * Y[:, 3]
    phi_r = (1.0 - eta_r) * beta_r * Y[:, 0] * Y[:, 4]

    Phi = np.empty((Y.shape[0], 2), dtype=np.float64, order="F")
    Phi[:, 0] = phi_s
    Phi[:, 1] = phi_r

    # 2. Terme linéaire : Y @ M.T (BLAS 3 DGEMM)
    # 3. Terme non-linéaire : Phi @ A.T (BLAS 3 DGEMM)
    # dY = S + Y @ M.T + Phi @ A.T
    dY = S + (Y @ M.T) + (Phi @ A.T)
    return dY


def simulate_cohort_rk4(
    Y0: np.ndarray,
    S: np.ndarray,
    eta: np.ndarray,
    M: np.ndarray,
    A: np.ndarray,
    beta_s: float,
    beta_r: float,
    days: float = 365.0,
    dt: float = 0.05,
    save_interval: int = 10,
) -> Tuple[np.ndarray, np.ndarray]:
    """
    Intégrateur Runge-Kutta d'ordre 4 matriciel pour la cohorte de N patients.

    Returns:
        times: Vecteur des temps enregistrés (K,)
        trajectory: Tenseur des états enregistrés (K, N, 5)
    """
    n_steps = int(np.ceil(days / dt))
    Y = Y0.copy(order="F")

    record_indices = list(range(0, n_steps + 1, save_interval))
    if record_indices[-1] != n_steps:
        record_indices.append(n_steps)

    times = np.array([idx * dt for idx in record_indices], dtype=np.float64)
    trajectory = np.zeros((len(record_indices), Y.shape[0], 5), dtype=np.
        float64)

    record_ptr = 0
    trajectory[record_ptr] = Y
    record_ptr += 1

    for step in range(1, n_steps + 1):
        # K1
        k1 = evaluate_cohort_rhs(Y, S, eta, M, A, beta_s, beta_r)

        # K2
        Y_k2 = Y + 0.5 * dt * k1
        k2 = evaluate_cohort_rhs(Y_k2, S, eta, M, A, beta_s, beta_r)

        # K3
        Y_k3 = Y + 0.5 * dt * k2
        k3 = evaluate_cohort_rhs(Y_k3, S, eta, M, A, beta_s, beta_r)

        # K4
        Y_k4 = Y + dt * k3
        k4 = evaluate_cohort_rhs(Y_k4, S, eta, M, A, beta_s, beta_r)
```

```
213
214         # Mise à jour RK4 matricielle
215         Y += (dt / 6.0) * (k1 + 2.0 * k2 + 2.0 * k3 + k4)
216
217         # Non-négativité biologique garantie
218         np.maximum(Y, 0.0, out=Y)
219
220         if step in record_indices[record_ptr:]:
221             trajectory[record_ptr] = Y
222             record_ptr += 1
223
224     return times, trajectory
```

Listing A.1 – Modèle matriciel vectorisé de la cohorte VIH (BLAS 3 / RK4).

A.2 Module d'Analyse Pronostique LAPACK (`src/lapack_analysis.py`)

```python
"""
Module d'analyse clinique et pronostique exploitant LAPACK et BLAS.
Implémente :
- La régression clinique multivariée par factorisation de Cholesky (DPOTRF + DPOTRS).
- L'Analyse en Composantes Principales (ACP) clinique via DSYEVD (Divide & Conquer).
- La comparaison avec l'inversion naïve explicite.
"""

from typing import Tuple, Dict
import numpy as np
from scipy.linalg import lapack, blas


def build_clinical_design_matrix(
    Y0: np.ndarray,
    eta: np.ndarray,
    S: np.ndarray,
) -> Tuple[np.ndarray, np.ndarray]:
    """
    Construit la matrice de design clinique X (N, P) et le vecteur cible y (N,).
    Variables explicatives :
    - Biais / Constante (1.0)
    - Nadir initial des CD4 sains (T0)
    - Charge virale initiale totale log10(V_s + V_r)
    - Niveau d'observance du patient (eta)
    - Production thymique individuelle (s_k)

    Cible y : Charge virale résiduelle log10(V_s + V_r + 1)
    """
    n_patients = Y0.shape[0]

    # 4 biomarqueurs initiaux + 1 terme de biais
    X = np.ones((n_patients, 5), dtype=np.float64, order="F")
    X[:, 1] = Y0[:, 0] / 1000.0                          # Nadir CD4 normalisé
    X[:, 2] = np.log10(Y0[:, 3] + Y0[:, 4] + 1.0)        # Log charge virale initiale
    X[:, 3] = eta                                        # Observance trithérapie
    X[:, 4] = S[:, 0] / 10.0                             # Production thymique relative

    return X


def solve_ridge_cholesky_lapack(
    X: np.ndarray,
    y: np.ndarray,
    alpha: float = 1e-3,
) -> Tuple[np.ndarray, Dict[str, float]]:
    """
    Résout le problème de régression clinique régularisée Ridge (X^T X + alpha*I) w = X^T y
    en utilisant les micro-noyaux BLAS 3 et LAPACK :
    1. DSYRK : calcul optimisé du produit de Gram symétrique G = X^T X (O(N * P^2)).
    2. DPOTRF : factorisation de Cholesky G = L @ L^T (O(1/3 * P^3)).
    3. DPOTRS : descente-remontée triangulaire pour résoudre sans inversion explicite.

```

```
    Returns:
        weights: Vecteur des coefficients de régression w (P,)
        stats: Métriques de performance et résidus
    """
    X_f = np.asfortranarray(X, dtype=np.float64)
    y_f = np.asfortranarray(y, dtype=np.float64)
    n, p = X_f.shape

    # 1. Produit de Gram G = X^T @ X via BLAS 3 dsyrk
    # G est symétrique (p, p)
    G = blas.dsyrk(alpha=1.0, a=X_f, trans=1, lower=1)
    # Remplissage de la partie supérieure pour symétrie complète
    G = G + np.tril(G, -1).T

    # Ajout de la régularisation de Tikhonov sur la diagonale
    np.fill_diagonal(G, G.diagonal() + alpha)

    # 2. Second membre b = X^T @ y via BLAS 2 dgemv
    b = blas.dgemv(alpha=1.0, a=X_f, x=y_f, trans=1)

    # 3. Factorisation de Cholesky via LAPACK dpotrf
    # G = L @ L^T
    L, info_potrf = lapack.dpotrf(G, lower=1)
    if info_potrf != 0:
        raise ValueError(f"DPOTRF a échoué (matrice non définie positive, info
            ={info_potrf})")

    # 4. Résolution triangulaire via LAPACK dpotrs
    w, info_potrs = lapack.dpotrs(L, b, lower=1)
    if info_potrs != 0:
        raise ValueError(f"DPOTRS a échoué (info={info_potrs})")

    # Calcul du résidu clinique
    predictions = X_f @ w
    residuals = y_f - predictions
    rmse = float(np.sqrt(np.mean(residuals ** 2)))
    r2 = float(1.0 - np.sum(residuals ** 2) / np.sum((y_f - np.mean(y_f)) ** 2)
        )

    return w, {"rmse": rmse, "r2": r2, "info_potrf": info_potrf}


def solve_ridge_naive_inverse(
    X: np.ndarray,
    y: np.ndarray,
    alpha: float = 1e-3,
) -> Tuple[np.ndarray, Dict[str, float]]:
    """
    Résolution par inversion explicite naïve w = (X^T X + alpha*I)^(-1) X^T y.
    Moins stable numériquement et non exploitante de la structure symétrique de
        Cholesky.
    """
    G = X.T @ X + alpha * np.eye(X.shape[1])
    G_inv = np.linalg.inv(G)
    w = G_inv @ (X.T @ y)

    predictions = X @ w
    residuals = y - predictions
    rmse = float(np.sqrt(np.mean(residuals ** 2)))
    r2 = float(1.0 - np.sum(residuals ** 2) / np.sum((y - np.mean(y)) ** 2))

    return w, {"rmse": rmse, "r2": r2}

```

```python

def compute_cohort_pca_lapack(
    trajectory_final: np.ndarray,
    n_components: int = 2,
) -> Tuple[np.ndarray, np.ndarray, np.ndarray]:
    """
    Analyse en Composantes Principales (ACP) de l'état clinique final de la cohorte
    via la routine LAPACK DSYEVD (Divide & Conquer Eigensolver).

    Parameters:
        trajectory_final: Matrice d'états finaux des N patients (N, 5)
        n_components: Nombre d'axes principaux à conserver (défaut: 2)

    Returns:
        projected: Coordonnées des patients sur les axes principaux (N, n_components)
        eigenvalues: Valeurs propres (variances expliquées) triées
        components: Vecteurs propres (axes directeurs)
    """
    # Centrage et réduction
    mean = np.mean(trajectory_final, axis=0)
    std = np.std(trajectory_final, axis=0)
    std[std == 0.0] = 1.0
    Z = (trajectory_final - mean) / std

    # Matrice de covariance (5, 5) via BLAS 3 dsyrk
    n_patients = Z.shape[0]
    Cov = blas.dsyrk(alpha=1.0 / (n_patients - 1), a=Z, trans=1, lower=1)
    Cov = Cov + np.tril(Cov, -1).T

    # Diagonalisation spectrale via LAPACK dsyevd (Divide & Conquer)
    w, v, info = lapack.dsyevd(Cov, compute_v=1, lower=1)
    if info != 0:
        raise ValueError(f"DSYEVD a échoué (info={info})")

    # Tri décroissant des valeurs propres
    idx = np.argsort(w)[::-1]
    sorted_w = w[idx]
    sorted_v = v[:, idx]

    # Projection des patients sur les composantes principales via BLAS 3 DGEMM
    projected = blas.dgemm(alpha=1.0, a=Z, b=sorted_v[:, :n_components])

    return projected, sorted_w, sorted_v[:, :n_components]
```

Listing A.2 – Régression Cholesky et ACP spectrale Divide & Conquer.

A.3 Module de Benchmark de Performance (`src/benchmark.py`)

```python
"""
Module de benchmark comparatif haute performance pour le modèle VIH.
Confronte les méthodes lentes naïves (Python pur) aux micro-noyaux BLAS 3, LAPACK et Intel MKL.
Mesure :
- Temps d'exécution (ms) et facteurs d'accélération (Speedup).
- Débits en GFLOPS et débit de patients simulés / seconde.
- Passage à l'échelle multithread OpenMP / Intel MKL.
"""

from typing import Dict, List, Tuple, Any
import time
import numpy as np
from scipy.linalg import lapack, blas

try:
    from threadpoolctl import threadpool_limits, threadpool_info
except ImportError:
    import contextlib
    @contextlib.contextmanager
    def threadpool_limits(limits=None, user_api=None):
        yield
    def threadpool_info():
        return [{'user_api': 'blas', 'internal_api': 'SciPy OpenBLAS/MKL (Native)', 'version': 'N/A'}]

from .cohort_model import (
    DEFAULT_PARAMS,
    build_cohort_parameters,
    initialize_cohort_state,
    simulate_cohort_rk4,
)
from .naive_model import simulate_cohort_naive_rk4
from .lapack_analysis import solve_ridge_cholesky_lapack, solve_ridge_naive_inverse


def get_hpc_system_info() -> Dict[str, str]:
    """
    Détecte la bibliothèque BLAS/LAPACK active en mémoire (Intel MKL, OpenBLAS, Accelerate).
    """
    info = threadpool_info()
    backends = [
        f"{d.get('internal_api', 'unknown')} ({d.get('version', '')})"
        for d in info if d.get('user_api') == 'blas'
    ]
    return {
        "blas_backend": ", ".join(backends) if backends else "SciPy BLAS/LAPACK",
        "detected_threads": str(len(info)),
    }


def measure_execution_time(fn, warmup: int = 1, repetitions: int = 3) -> float:
    """
    Mesure le temps d'exécution minimal sur un nombre de répétitions après phase de chauffe.
    """
    for _ in range(warmup):
        fn()
```

```
    times = []
    for _ in range(repetitions):
        t0 = time.perf_counter()
        fn()
        times.append(time.perf_counter() - t0)
    return float(min(times))


def benchmark_simulation_naive_vs_mkl(
    cohort_sizes: List[int] = [50, 100, 200, 500],
    days: float = 30.0,
    dt: float = 0.05,
    threads: int = 4,
) -> List[Dict[str, Any]]:
    """
    Compare directement l'intégration temporelle naïve (boucle Python pur)
    face à l'intégration matricielle BLAS 3 / Intel MKL.
    """
    results = []
    p = DEFAULT_PARAMS

    for n in cohort_sizes:
        S, eta, M, A = build_cohort_parameters(n_patients=n, params=p, seed
            =2026)
        Y0 = initialize_cohort_state(n_patients=n, S=S, params=p, seed=2026)

        # Préparation des données listes pour la méthode naïve
        y0_list = Y0.tolist()
        s_list = S[:, 0].tolist()
        eta_list = eta.tolist()

        # 1. Mesure méthode naïve lente
        t_naive = measure_execution_time(
            lambda: simulate_cohort_naive_rk4(
                y0_list=y0_list,
                s_list=s_list,
                eta_list=eta_list,
                d=p["d"],
                delta=p["delta"],
                p=p["p"],
                c=p["c"],
                beta_s=p["beta_s"],
                beta_r=p["beta_r"],
                mu=p["mu"],
                days=days,
                dt=dt,
            ),
            warmup=1,
            repetitions=2,
        )

        # 2. Mesure méthode optimisée BLAS 3 / MKL
        with threadpool_limits(limits=threads, user_api="blas"):
            t_mkl = measure_execution_time(
                lambda: simulate_cohort_rk4(
                    Y0=Y0,
                    S=S,
                    eta=eta,
                    M=M,
                    A=A,
                    beta_s=p["beta_s"],
                    beta_r=p["beta_r"],
                    days=days,
```

```
                    dt=dt,
                    save_interval=max(1, int(days / dt)),
                ),
                warmup=1,
                repetitions=3,
            )

        speedup = t_naive / t_mkl if t_mkl > 0 else 0.0
        throughput_mkl = n / t_mkl if t_mkl > 0 else 0.0

        results.append({
            "n_patients": n,
            "days_simulated": days,
            "time_naive_ms": t_naive * 1000.0,
            "time_mkl_ms": t_mkl * 1000.0,
            "speedup": speedup,
            "throughput_patients_per_sec": throughput_mkl,
        })

    return results


def benchmark_large_cohort_scaling(
    cohort_sizes: List[int] = [1000, 2000, 5000, 10000],
    days: float = 60.0,
    dt: float = 0.05,
    threads: int = 4,
) -> List[Dict[str, Any]]:
    """
    Évalue la montée en charge de la version MKL pour de très grandes cohortes de patients.
    Calcule le débit en GFLOPS effectifs.
    """
    results = []
    p = DEFAULT_PARAMS
    n_steps = int(days / dt)

    with threadpool_limits(limits=threads, user_api="blas"):
        for n in cohort_sizes:
            S, eta, M, A = build_cohort_parameters(n_patients=n, params=p, seed=2026)
            Y0 = initialize_cohort_state(n_patients=n, S=S, params=p, seed=2026)

            t_sim = measure_execution_time(
                lambda: simulate_cohort_rk4(
                    Y0=Y0,
                    S=S,
                    eta=eta,
                    M=M,
                    A=A,
                    beta_s=p["beta_s"],
                    beta_r=p["beta_r"],
                    days=days,
                    dt=dt,
                    save_interval=n_steps,
                ),
                warmup=1,
                repetitions=3,
            )

            # Nombre d'opérations FLOPs :
            # À chaque évaluation de RHS :
```

```
            # - Flux non-linéaires : ~6 * N FLOPs
            # - Y @ M.T : 2 * N * 5 * 5 = 50 * N FLOPs
            # - Phi @ A.T : 2 * N * 2 * 5 = 20 * N FLOPs
            # - Additions : 2 * 5 * N = 10 * N FLOPs
            # Total par RHS = ~86 * N FLOPs
            # RK4 = 4 évaluations RHS + mise à jour (10 * N) = ~354 * N FLOPs par pas
            total_flops = float(n_steps) * 354.0 * float(n)
            gflops = total_flops / (t_sim * 1e9) if t_sim > 0 else 0.0

            results.append({
                "n_patients": n,
                "time_ms": t_sim * 1000.0,
                "gflops": gflops,
                "throughput_patients_per_sec": n / t_sim if t_sim > 0 else 0.0,
            })

    return results


def benchmark_lapack_cholesky_vs_naive(
    cohort_sizes: List[int] = [1000, 5000, 10000, 20000],
    n_features: int = 15,
) -> List[Dict[str, Any]]:
    """
    Compare l'analyse clinique par LAPACK Cholesky (DPOTRF+DPOTRS+DSYRK)
    face à l'inversion explicite naïve (np.linalg.inv).
    """
    results = []
    rng = np.random.default_rng(2026)

    for n in cohort_sizes:
        # Données cliniques synthétiques
        X = rng.standard_normal((n, n_features))
        y = rng.standard_normal(n)

        # 1. LAPACK Cholesky
        t_lapack = measure_execution_time(
            lambda: solve_ridge_cholesky_lapack(X, y, alpha=1e-3),
            warmup=1,
            repetitions=3,
        )

        # 2. Inversion naïve explicite
        t_naive = measure_execution_time(
            lambda: solve_ridge_naive_inverse(X, y, alpha=1e-3),
            warmup=1,
            repetitions=3,
        )

        speedup = t_naive / t_lapack if t_lapack > 0 else 0.0

        results.append({
            "n_patients": n,
            "n_features": n_features,
            "time_lapack_ms": t_lapack * 1000.0,
            "time_naive_ms": t_naive * 1000.0,
            "speedup": speedup,
        })

    return results


```

```python
def benchmark_thread_scalability(
    n_patients: int = 10000,
    thread_counts: List[int] = [1, 2, 4, 8],
    days: float = 60.0,
) -> List[Dict[str, Any]]:
    """
    Mesure le passage à l'échelle (Speedup et Efficacité) en fonction du nombre de threads MKL.
    """
    p = DEFAULT_PARAMS
    S, eta, M, A = build_cohort_parameters(n_patients=n_patients, params=p, seed=2026)
    Y0 = initialize_cohort_state(n_patients=n_patients, S=S, params=p, seed=2026)

    # Référence 1 thread (temps séquentiel T1)
    with threadpool_limits(limits=1, user_api="blas"):
        t_base = measure_execution_time(
            lambda: simulate_cohort_rk4(
                Y0=Y0, S=S, eta=eta, M=M, A=A,
                beta_s=p["beta_s"], beta_r=p["beta_r"],
                days=days, dt=0.05, save_interval=int(days / 0.05),
            ),
            warmup=1,
            repetitions=3,
        )

    results = []
    for th in thread_counts:
        with threadpool_limits(limits=th, user_api="blas"):
            t_curr = measure_execution_time(
                lambda: simulate_cohort_rk4(
                    Y0=Y0, S=S, eta=eta, M=M, A=A,
                    beta_s=p["beta_s"], beta_r=p["beta_r"],
                    days=days, dt=0.05, save_interval=int(days / 0.05),
                ),
                warmup=1,
                repetitions=3,
            )

        speedup = t_base / t_curr
        efficiency = (speedup / th) * 100.0

        results.append({
            "threads": th,
            "time_ms": t_curr * 1000.0,
            "speedup": speedup,
            "efficiency_percent": efficiency,
        })

    return results
```

Listing A.3 – Campagne de benchmarks comparatifs Naïf vs BLAS 3 / Intel MKL.